

Análisis Automatizado de la Estética de Emplatado mediante Técnicas de Inteligencia Artificial y Visión por Computadora

Mariana Jaqueline Peñaran Prieto^{1,*} and Ángel Díaz Pacheco¹

¹División de Ingenierías del Campus Irapuato - Salamanca, Universidad de Guanajuato. Carr. Salamanca-Valle de Santiago km 3.5 + 1.8; Comunidad de Palo Blanco, Salamanca, 36885, Guanajuato, México.

*Autor de correspondencia: mj.penaranprieto@ugto.mx

Resumen

La evaluación estética del emplatado gastronómico es un proceso tradicionalmente subjetivo, lo que dificulta su estandarización en entornos educativos. Este reporte presenta el desarrollo de una herramienta de visión por computadora diseñada para evaluar de manera objetiva la similitud estética entre un platillo elaborado por un estudiante y su referencia experta. La metodología integra técnicas de segmentación, alineación estructural y un enfoque híbrido de extracción de características que combina descriptores clásicos como HOG, EMD y SSIM con representaciones profundas obtenidas mediante VGG16. A diferencia de enfoques puramente supervisados que mostraron sobreajuste debido a la escasez de datos, se optó por un esquema de ponderación experimental. Los resultados preliminares demuestran que el sistema es robusto ante transformaciones leves, aunque presenta desafíos en la capacidad discriminativa fina entre categorías de calidad cercana. Este estudio sienta las bases para una retroalimentación automatizada en la formación culinaria.

Palabras clave: Visión por computadora, Estética culinaria, Aprendizaje profundo, Procesamiento de imágenes.

1. Introduction

En el ámbito gastronómico, la presentación visual de los platillos constituye un elemento esencial que influye directamente en la percepción estética, el valor culinario y la experiencia sensorial del comensal. La estética del emplatado no solo refleja la creatividad del chef, sino también su dominio técnico y su capacidad para transmitir equilibrio, simetría y armonía visual. No obstante, la evaluación de este aspecto suele depender de criterios subjetivos, lo que introduce sesgos y dificulta la estandarización de los procesos de enseñanza y evaluación en la formación gastronómica.

Ante esta problemática, surge la necesidad de desarrollar herramientas que permitan realizar una evaluación objetiva y reproducible de la estética culinaria. En este contexto, el presente proyecto propone la creación de un sistema de análisis automatizado del emplatado basado en técnicas de inteligencia artificial y visión por computadora, cuyo propósito es comparar la presentación de un platillo elaborado por un estudiante con una imagen de referencia correspondiente al diseño del chef instructor.

El sistema implementa una arquitectura modular compuesta por diversos procesos que actúan de forma secuencial para analizar y comparar las imágenes. Entre las etapas desarrolladas hasta el momento se incluyen la segmentación, el preprocesamiento y alineación, la extracción de características visuales y la asignación de una calificación inicial. En la primera etapa se realiza la segmentación de la imagen con el fin de aislar el platillo y eliminar elementos de ruido que puedan interferir en el análisis. Posteriormente, se lleva a cabo un preprocesamiento que incluye la normalización del tamaño y la alineación de las imágenes, garantizando condiciones comparables. La tercera etapa corresponde a la extracción de características, donde se calculan métricas visuales clásicas y profundas. Finalmente, las

métricas obtenidas se ponderan y combinan mediante un esquema de pesos ajustables para generar una calificación numérica representativa del grado de similitud estética entre ambas imágenes.

El desarrollo de esta herramienta busca aportar un recurso didáctico que permita evaluar de manera objetiva y reproducible la estética culinaria, apoyando los procesos de enseñanza y aprendizaje en instituciones gastronómicas. Además, sienta las bases para futuras etapas del proyecto orientadas a la generación de retroalimentación visual, la integración de una interfaz gráfica y la automatización de reportes, consolidando así una solución completa de apoyo académico. Este trabajo representa un avance hacia la incorporación de la inteligencia artificial en el ámbito gastronómico, mostrando su potencial para aproximar criterios humanos de apreciación visual.

2. Estado del Arte

La intersección entre la inteligencia artificial y la visión por computadora ha abierto nuevas fronteras en campos tradicionalmente subjetivos, como la estética, el arte y la gastronomía. El análisis de imágenes de alimentos ha evolucionado desde la clasificación de ingredientes, como en el conjunto de datos Food-101 (Bossard et al., 2014), hacia tareas más complejas: estimación nutricional, generación de recetas y, más recientemente, evaluación de la calidad estética (Min et al., 2019; Kakani et al., 2020; Liu et al., 2025). Estas revisiones muestran un interés creciente por objetivar criterios de calidad y seguridad en la industria alimentaria mediante técnicas de visión por computadora.

El desafío central en la evaluación estética de platillos es la cuantificación de criterios perceptuales humanos, como la armonía, el balance de color y la composición, que tradicionalmente son subjetivos. Las Redes Neuronales Convolucionales (CNNs), como VGG16 y ResNet, han demostrado ser herramientas eficaces para extraer características visuales profundas relevantes para la estética. Trabajos sobre medición de la calidad estética de imágenes de comida muestran que arquitecturas basadas en VGG y ResNet pueden predecir distribuciones de calificaciones humanas (Lou et al., 2018), lo anterior demuestra que las redes pueden aprender representaciones visuales consistentes con los juicios humanos, aunque, al provenir de un proyecto universitario, los resultados deben interpretarse con cautela.

No obstante, la información semántica profunda que extraen las CNNs no cubre completamente todos los aspectos perceptuales. La literatura apoya enfoques híbridos que combinan descriptores clásicos, como HOG y LBP, con representaciones profundas. Una revisión reciente sobre reconocimiento de alimentos y métodos de análisis reporta que los descriptores clásicos siguen siendo útiles para capturar forma y textura, y que su combinación con extracción profunda mejora la robustez del sistema (Liu et al., 2025). Esta sinergia es particularmente relevante cuando las variaciones de imagen, como iluminación, ángulo o resolución, afectan el rendimiento de los modelos basados solo en CNN.

La selección de métricas de similitud y calidad perceptual también es crucial. El Índice de Similitud Estructural (SSIM) sigue siendo un referente para comparar estructuras perceptuales entre imágenes (Wang et al., 2004), porque modela mejor la percepción humana que medidas de error punto a punto. Para la comparación de color perceptual, métricas como Earth Mover's Distance (EMD) han mostrado buenos resultados en trabajos de estética de alimentos. Estudios aplicados usan EMD para validar correspondencia con evaluaciones humanas de color y composición (Mikhailava et al., 2020), por lo que resulta una elección adecuada para sistemas que buscan alinearse con juicios visuales humanos.

De particular relevancia para este proyecto es el estudio que evalúa la transferencia de habilidades culinarias comparando imágenes de estudiantes y chefs (Castillo-Ortiz et al., 2024). Ese trabajo aplica VGG-16 y medidas de similitud, por ejemplo, la similitud del coseno, para cuantificar la cercanía entre imágenes; sin embargo, sus autores señalan limitaciones importantes: discrepancias entre métricas automatizadas y juicios humanos, y alta sensibilidad a la calidad y el ángulo de captura de las imágenes. Estas conclusiones delimitan la brecha de investigación que aborda el presente proyecto.

Para mitigar esas discrepancias, este trabajo propone un enfoque híbrido y perceptual: ponderar características profundas extraídas con VGG16 junto con métricas estructurales, de color perceptual y de forma. Dicha combinación busca reducir la sensibilidad a variaciones de adquisición y mejorar la alineación con juicios humanos, posicionando la propuesta como una mejora práctica y metodológica respecto a los trabajos previos en evaluación culinaria automatizada.

3. Metodología general del sistema

El sistema desarrollado tiene como finalidad evaluar de manera objetiva la estética del emplatado en imágenes gastronómicas, comparando la composición visual del platillo elaborado por un estudiante con una imagen de referencia proporcionada por el chef instructor. Para ello, se implementa una metodología basada en visión por computadora e inteligencia artificial, compuesta por una serie de etapas secuenciales que procesan, transforman y analizan la información visual hasta generar una calificación cuantitativa de similitud estética.

El diseño metodológico sigue una arquitectura modular, donde cada componente cumple una función específica dentro del flujo general de análisis. Esta estructura permite una evolución progresiva del sistema, facilitando la incorporación futura de módulos adicionales, como la generación de retroalimentación visual y la implementación de una interfaz gráfica interactiva.

A continuación, se describen de manera detallada los procesos principales que conforman la metodología de esta primera etapa del proyecto.

3.1. Segmentación de imágenes

El primer paso consiste en la segmentación del platillo dentro de la imagen original. Este proceso tiene como propósito eliminar el fondo y cualquier elemento que pueda interferir con el análisis visual, tales como sombras, utensilios o superficies de apoyo.

Para ello se emplea el algoritmo *GrabCut*, implementado en la biblioteca OpenCV. Este método combina técnicas de modelado de color mediante mezclas gaussianas (GMM) y minimización de energía para separar de forma semiautomática los píxeles correspondientes al objeto principal (platillo) del fondo.

El usuario selecciona manualmente un rectángulo de interés sobre la región del platillo, lo que permite inicializar el modelo de segmentación. *GrabCut* itera entre las fases de clasificación de píxeles y ajuste de los modelos de color hasta converger en una máscara binaria que representa con alta precisión el área del platillo.

Debido a la complejidad de las imágenes gastronómicas, donde pueden presentarse bordes irregulares o artefactos visuales, se aplica un postprocesamiento morfológico sobre la máscara obtenida. Este incluye:

- **Apertura morfológica** para eliminar elementos delgados o conexiones no deseadas.
- **Cierre morfológico** para rellenar huecos internos y garantizar la continuidad del objeto.
- **Inpainting con el método de Telea** que reconstruye regiones inconsistentes en la máscara final, logrando una superficie más homogénea del platillo.

El resultado de este proceso es una imagen segmentada precisa, donde únicamente se conserva el área del platillo sobre un fondo neutro. En la Figura 1 se visualiza este procedimiento aplicado al platillo Pollo Relleno, demostrando la capacidad del sistema para aislar geometrías complejas del entorno.



Figura 1: Ejemplo del proceso de segmentación mediante GrabCut aplicado al Pollo Relleno.

3.2. Preprocesamiento y alineación

Una vez obtenidas las imágenes segmentadas, se procede con la fase de preprocesamiento, cuyo objetivo es garantizar que ambas imágenes se encuentren bajo condiciones visuales comparables.

Este módulo ejecuta las siguientes tareas:

1. **Redimensionamiento:** Todas las imágenes se ajustan a un tamaño fijo de 224×224 píxeles, permitiendo la compatibilidad con redes neuronales como VGG16.
2. **Corrección de orientación y rotación segura:** Se calcula el ángulo de orientación del platillo mediante el contorno principal y el rectángulo mínimo de área. A partir de este ángulo, se genera una matriz de rotación centrada en el objeto, evitando recortes en los bordes.
3. **Alineación entre imágenes:** Se comparan las imágenes en su orientación original y rotadas 180° . Se calcula la Similitud Estructural para ambas versiones, conservando aquella con mayor valor de similitud.

De este modo, las imágenes quedan alineadas y preparadas para el análisis comparativo. La Figura 2 ilustra la eficacia de este módulo: se toma como meta la referencia alineada del instructor y se transforma la imagen rotada del estudiante hasta hacerla coincidir espacialmente.




Figura 2: Proceso de alineación. (a) Imagen de referencia final. (b) Imagen del estudiante con rotación arbitraria. (c) Imagen del estudiante corregida, mostrando coincidencia espacial con la referencia.

3.3. Extracción de características visuales

En esta primera etapa, se implementaron tanto métodos clásicos de visión por computadora como técnicas de aprendizaje profundo. Dado que el sistema integra métricas de naturaleza heterogénea algunas de similitud y otras de distancia, se estableció un protocolo de unificación: todas las métricas de distancia (d) fueron transformadas a valores de similitud (s) mediante la función de inversión:

$$s = \frac{1}{1 + d}$$

De este modo, se garantiza que para todas las características descritas a continuación, un valor más alto siempre indica una mayor coincidencia estética entre la imagen del estudiante y la referencia.

Las características extraídas son:

- **Similitud estructural (SSIM):** Mide el grado de semejanza considerando luminancia, contraste y estructura. Es una métrica nativa de similitud cuyo valor oscila directamente entre 0 y 1, donde 1 representa una coincidencia perfecta.
- **Distancia EMD (Earth Mover's Distance):** Evalúa la similitud entre distribuciones de color interpretando los histogramas en el espacio HSV como distribuciones de masa. Al ser originalmente una métrica de distancia, se aplica la transformación inversa para su integración en el sistema.

- **Descriptores HOG (Histogram of Oriented Gradients):** Capturan información relacionada con la forma y los contornos principales del platillo. Se calcula la distancia euclidiana entre los vectores HOG de ambas imágenes, la cual es posteriormente convertida a similitud.
- **Embeddings profundos (VGG16):** se emplea la arquitectura preentrenada VGG16 (entrenada con ImageNet) como extractor de características profundas. Se conserva la salida de la capa de *pooling* global promedio, obteniendo un vector de representación de alta dimensionalidad. La similitud entre los vectores de la imagen del chef y del estudiante se calcula mediante la similitud del coseno, cuyo valor también varía entre 0 y 1.
- **Métrica Chi-cuadrado:** Utilizada tradicionalmente para comparar histogramas de color entre dos imágenes. Esta métrica cuantifica la diferencia entre las distribuciones de frecuencia de color, evaluando cuánto se desvían los valores de un histograma con respecto al otro. Su formulación general es:

$$\chi^2 = \frac{1}{2} \sum_{i=1}^n \frac{(H_1(i) - H_2(i))^2}{H_1(i) + H_2(i) + \epsilon}$$

donde $H_1(i)$ y $H_2(i)$ representan los valores del bin i en los histogramas de las dos imágenes y ϵ es una constante pequeña para evitar divisiones por cero. Aunque esta métrica proporciona una evaluación rápida y sencilla de diferencias cromáticas, en esta versión del sistema se le asignó un peso de 0, dado que la métrica EMD ofrece una representación más perceptualmente coherente del color al considerar la “distancia de transporte” entre distribuciones.

- **Descriptores LBP (Local Binary Patterns):** Son una técnica clásica de descripción de textura que codifica las variaciones locales de intensidad en torno a cada píxel. El método consiste en comparar el valor de cada píxel con los de su vecindario circular y asignar una codificación binaria de acuerdo con la relación de intensidad. El resultado es un mapa de patrones binarios locales que se representa como un histograma de frecuencias. La similitud entre dos texturas se mide mediante la distancia Chi-cuadrado entre sus histogramas.

A pesar de su eficiencia y bajo costo computacional, el descriptor LBP fue descartado en la ponderación final del modelo con un peso de 0 debido a su sensibilidad al ruido y a las variaciones de iluminación en las imágenes gastronómicas.

Finalmente, al estar todas las métricas unificadas como valores de similitud en el rango $[0, 1]$, es posible combinarlas coherentemente dentro del esquema ponderado de calificación.

3.4. Evaluación y asignación de calificación

Con las métricas obtenidas, el sistema procede a su normalización y combinación ponderada para generar una calificación final.

Cada métrica se ajusta a una escala entre 0 y 1 y se pondera según su relevancia experimental. Los pesos definidos en esta fase son:

Métrica	Peso asignado
VGG16 (representación profunda)	0.50
SSIM (similitud estructural)	0.20
EMD (color perceptual)	0.10
HOG (forma)	0.20
LBP	0.00
Chi-cuadrado	0.00

La calificación final se calcula mediante una combinación lineal ponderada de las métricas normalizadas:

$$P = 1 + 9 \times \sum_{i=1}^n (w_i \cdot s_i)$$

donde w_i representa el peso asignado a cada métrica y s_i su valor normalizado. El resultado P se expresa en una escala de 1 a 10, que representa el nivel de similitud estética del platillo del estudiante respecto a la referencia.

4. Experimentos realizados

Se evaluó la pertinencia de incorporar etapas avanzadas de preprocesamiento para mejorar la calidad de las imágenes. Se experimentó con la aplicación de filtros de suavizado como el Gaussiano y Filtro de Mediana para la reducción de ruido, así como con técnicas de ecualización de histograma incluyendo CLAHE para normalizar la iluminación y el contraste.

Sin embargo, los resultados visuales y métricos indicaron que estas operaciones eran contraproducentes para el dominio gastronómico. Los filtros de suavizado tendían a eliminar texturas finas esenciales del platillo, haciendo que la comida luciera artificial. Por su parte, la ecualización de histograma introducía artefactos de color no naturales y saturaba excesivamente las zonas de brillo, alterando la percepción estética real. Por estas razones, se optó por mantener un preprocesamiento conservador, limitándose a la segmentación y alineación geométrica para preservar la integridad visual original del platillo.

Posteriormente, durante el desarrollo del sistema se realizaron múltiples experimentos orientados a determinar si era posible asignar de manera automática un peso óptimo a cada métrica empleada en la evaluación estética. Para ello, se entrenaron distintos modelos de regresión supervisada con el objetivo de aprender la relación entre las métricas calculadas *Chi-Square*, *EMD*, *HOG*, *LBP*, *VGG16* y *SSIM* y las calificaciones ideales definidas manualmente para cada imagen de referencia.

En una primera etapa, se emplearon modelos clásicos de aprendizaje automático como *Support Vector Regressor* (SVR), *Random Forest Regressor* y una red neuronal *Multi-Layer Perceptron* (MLP). Los datos fueron normalizados mediante *StandardScaler* y evaluados utilizando el error cuadrático medio (MSE). Si bien los modelos lograron reproducir las calificaciones de entrenamiento, el análisis reveló un sobreajuste evidente, especialmente en el caso del MLP, cuyo error de entrenamiento fue prácticamente nulo (MSE = 0.003) pero sin capacidad real de generalización. La validación cruzada confirmó esta tendencia, mostrando pérdidas elevadas y falta de consistencia en las predicciones.

Posteriormente se probaron variantes del MLP con normalización *MinMaxScaler* y con arquitecturas ajustadas mediante técnicas de *early stopping* y regularización. Aunque estos intentos redujeron parcialmente la varianza, los modelos seguían convergiendo hacia soluciones inestables o sesgadas, generando predicciones agrupadas en torno a un valor promedio (alrededor de 6 puntos) independientemente de la calidad de la imagen. Esto indicaba que el conjunto de datos disponible era insuficiente para capturar relaciones significativas entre las métricas y las calificaciones esperadas.

También se ensayó un modelo de regresión lineal. Si bien permitió observar la dirección de influencia de cada característica, los coeficientes aprendidos mostraron una alta dispersión, con pesos negativos o desproporcionados en métricas como HOG y Chi-Square, lo que confirmó la inestabilidad del ajuste. En todos los casos, los errores en validación (MSE > 10) y la incapacidad de generalizar a nuevas imágenes llevaron a descartar la asignación automática de pesos mediante entrenamiento supervisado.

Ante estos resultados, se optó finalmente por establecer una ponderación experimental basada en el análisis empírico de las métricas y su contribución perceptual a la evaluación estética. Los pesos definitivos asignados fueron: VGG16 (0.50), SSIM (0.20), HOG (0.20), EMD (0.10), y valores nulos para LBP y Chi-Square, debido a su escasa correlación con la percepción visual del platillo. Este esquema permitió obtener calificaciones más coherentes y consistentes entre versiones, evitando el sobreajuste y manteniendo la interpretabilidad del modelo.

5. Resultados

En esta etapa se analizaron los resultados obtenidos tras la evaluación de las distintas versiones de cada platillo. Para garantizar la fiabilidad del análisis de robustez, el estudio se centró en los tres platillos que contaban con un conjunto de imágenes completo y en condiciones óptimas: Omelette, Parmentier y Pollo Relleno. Se descartaron dos categorías adicionales (Limon y Pollo Frito), dado que el material visual disponible para ellas presentaba inconsistencias significativas, como imágenes cortadas o incompletas, que impedían una comparación fiable y comprometían la validez de las pruebas.

El objetivo principal fue verificar la robustez del sistema frente a transformaciones controladas de las imágenes (variaciones en brillo, rotación y ligera traslación), garantizando que la calificación otorgada se mantuviera estable ante cambios menores que no alteran la composición visual esencial del platillo.

Para cada uno de los tres platillos seleccionados, se consideraron cinco versiones generadas bajo condiciones homogéneas. La calificación fue calculada en función de las métricas descritas previamente, utilizando los pesos definidos en la Tabla anterior. Posteriormente, se analizaron los resultados mediante tres visualizaciones clave que permiten examinar la consistencia y estabilidad del sistema.

5.1. Distribución de calificaciones por platillo

La Figura 3 muestra la distribución de calificaciones obtenidas para las cinco versiones de cada platillo. Se observa que el Omelette presenta la mediana más alta (aproximadamente 6.15), aunque también exhibe la mayor dispersión entre versiones, reflejada en un rango intercuartílico amplio y una extensión de valores que va desde 5.85 hasta cerca de 6.50.

Por su parte, el Parmentier muestra una mediana ligeramente inferior (en torno a 5.96), pero con una variabilidad mucho menor, evidenciada por una caja más compacta. Finalmente, el Pollo Relleno presenta la mediana más baja (aproximadamente 5.76) y una ligera mayor dispersión hacia valores inferiores (alrededor de 5.64), lo que indica una menor estabilidad en sus calificaciones frente a las variaciones introducidas.




Figura 3: Distribución de calificaciones obtenidas por las distintas versiones de cada platillo.

5.2. Media de calificación por platillo

La Figura 4 presenta la media de calificación por platillo, acompañada de sus respectivas barras de error que representan la desviación estándar. Los resultados confirman la tendencia observada en el boxplot: el Omelette obtiene la media más alta (ligeramente superior a 6.1), seguido del Parmentier (cerca de 5.95) y del Pollo Relleno (alrededor de 5.85).

Las barras de error permiten observar que el Parmentier presenta una menor variabilidad, lo que indica un comportamiento más estable del sistema al evaluar este platillo. En cambio, el Omelette y el Pollo Relleno exhiben una dispersión moderadamente mayor, lo cual sugiere una leve sensibilidad del sistema ante cambios visuales en estos casos.




Figura 4: Media de calificaciones por platillo.

5.3. Desviación estándar y análisis de robustez

La Figura 5 presenta el indicador directo de la robustez del sistema: la desviación estándar de las calificaciones por platillo. Un valor más bajo implica una mayor consistencia en las evaluaciones (mayor robustez) ante las transformaciones controladas.

El Parmentier muestra la desviación estándar más baja (aproximadamente 0.038), consolidándose como el platillo cuya evaluación fue más estable y consistente. Le sigue el Omelette con una desviación intermedia (alrededor de 0.046), mientras que el Pollo Relleno presenta la mayor desviación (cercana a 0.058), evidenciando una ligera sensibilidad del modelo a los cambios de iluminación o posición en este caso.




Figura 5: Desviación estándar de las calificaciones por platillo.

A pesar de estas diferencias relativas, cabe destacar que todos los valores de desviación estándar son numéricamente pequeños (todos por debajo de 0.06). Esto confirma que, en términos generales, el sistema de evaluación mantiene un alto grado de estabilidad y coherencia al analizar diferentes versiones del mismo platillo, cumpliendo con el objetivo de robustez de esta prueba.


5.4. Análisis de Discriminación Cualitativa

Como hallazgo relevante, se observó que las calificaciones obtenidas por el sistema tendían a concentrarse en un rango estrecho, sin una separación marcada entre las categorías “Óptimo”, “Regular” y “Deficiente”. Aunque las puntuaciones seguían en general el orden esperado, las diferencias numéricas entre ellas eran pequeñas, lo que indica que el sistema aún requiere un mayor rango discriminativo.

Para explorar este comportamiento, se analizaron las calificaciones finales de platillos clasificados manualmente como “Óptimo”, “Regular” y “Deficiente”. Se identificaron dos comportamientos principales: casos de alineación con el juicio humano y casos de discrepancia.

La **Tabla 1** muestra un caso de alineación exitosa. Para el Omelette, el sistema asignó correctamente la calificación más alta a la versión “Óptima” (9.07), seguida de la “Regular” (8.85) y la “Deficiente” (8.51). Esto demuestra que la ponderación de métricas (VGG16, SSIM, HOG, EMD) es capaz de seguir la lógica perceptual humana en este platillo.

Tabla 1: Resultados de Discriminación (Platillo: Omelette) - Caso de Alineación

Ref. (Chef)	Estudiante (Eval.)	VGG16	SSIM	HOG (Sim.)	EMD (Sim.)	Calif. Final
	Óptima 	0.927	0.681	0.998	0.966	9.07
	Regular 	0.881	0.674	0.998	0.977	8.85
	Deficiente 	0.815	0.653	0.998	0.967	8.51

Por el contrario, la **Tabla 2** ilustra un caso de discrepancia severa, un hallazgo consistente con las limitaciones reportadas en el estado del arte (Castillo-Ortiz et al., 2024). Para el Parmentier, el sistema invirtió completamente el orden de evaluación, calificando la versión “Deficiente” (8.70) como la mejor y la versión “Óptima” (8.48) como la peor.

Tabla 2: Resultados de Discriminación (Platillo: Parmentier) - Caso de Discrepancia

Ref. (Chef)	Estudiante (Eval.)	VGG16	SSIM	HOG (Sim.)	EMD (Sim.)	Calif. Final
	Óptima 	0.875	0.478	0.998	0.980	8.48
	Regular 	0.891	0.570	0.998	0.968	8.70
	Deficiente 	0.907	0.482	0.998	0.970	8.62

Esta discrepancia, ocurrida precisamente en el platillo que mostró la mayor robustez (menor desviación estándar), subraya una limitación clave del modelo. Al analizar las métricas normalizadas del Parmentier, se observa que la versión “Deficiente” obtuvo un score de VGG16 (0.891) y SSIM (0.570) más altos que la versión “Óptima” (0.875 y 0.478, respectivamente).

Dado que VGG16 y SSIM suman el 70 % del peso total ($0.50 + 0.20$), el sistema priorizó estas características sobre la evaluación perceptual humana, inflando la calificación. Este hallazgo sugiere que la ponderación actual, aunque estable, es incorrecta para este tipo de platillo y requiere un reajuste, posiblemente dando más relevancia a la métrica de color EMD, que sí puntuó mejor a la versión “Óptima” (0.980).

6. Discusión

Los resultados obtenidos en esta primera fase permiten realizar un análisis crítico del comportamiento del sistema frente a variaciones controladas en las imágenes. La baja desviación estándar observada en las calificaciones de los tres platillos (<0.06) sugiere que el modelo es estable y consistente cuando las transformaciones aplicadas no modifican significativamente la estructura visual del platillo. Esto indica que las métricas utilizadas, particularmente SSIM, HOG y VGG16, responden adecuadamente a diferencias perceptuales leves, manteniendo una coherencia general entre versiones de una misma referencia.

Sin embargo, la concentración de las calificaciones en un rango estrecho evidencia una limitación importante en la capacidad discriminativa del sistema. Si bien las puntuaciones siguen la tendencia esperada, las diferencias numéricas son pequeñas, lo que sugiere que el modelo tiende a suavizar las variaciones estéticas. Este comportamiento puede atribuirse a la ponderación relativamente alta de la métrica VGG16, la cual prioriza la similitud semántica global sobre los detalles compositivos o de color que influyen de manera más directa en la percepción estética. Esta limitación se hizo evidente en el análisis cualitativo del Parmentier, donde la predominancia de la estructura sobre el color generó una discrepancia con el juicio humano, confirmando la necesidad de explorar esquemas de ponderación dinámicos o dependientes de la categoría.

Otro factor relevante es la sensibilidad del sistema ante las condiciones de iluminación y encuadre. Aunque el proceso de alineación y normalización reduce la variabilidad producida por el ángulo o la rotación, diferencias de brillo o contraste entre las imágenes del chef y las versiones estudiadas pueden afectar la respuesta de métricas estructurales y de textura. Esto explica las leves variaciones entre platillos, especialmente en el caso del Pollo Relleno, donde la iluminación original difiere de manera más notoria entre capturas.

En términos generales, el desempeño observado demuestra que la arquitectura propuesta es funcional y que las métricas seleccionadas capturan de manera razonable la similitud estética entre platillos. No obstante, el sistema aún requiere un ajuste fino en el esquema de ponderación.

El análisis de robustez constituye un paso fundamental para validar la estabilidad del modelo, pero los hallazgos también revelan la necesidad de escalar la evaluación hacia conjuntos de datos más amplios y diversos. Solo así podrá determinarse con mayor certeza si las tendencias observadas son consistentes a través de distintas categorías gastronómicas y condiciones de captura. En este sentido, los resultados aquí presentados deben considerarse como una validación inicial del potencial del enfoque propuesto más que como una evaluación definitiva de su desempeño global.

7. Conclusiones y trabajo futuro

En esta primera fase del proyecto se logró desarrollar un sistema funcional capaz de evaluar la similitud estética entre imágenes gastronómicas mediante la integración de técnicas de visión por computadora y aprendizaje profundo. El sistema implementa correctamente las etapas de segmentación, alineación, extracción de características y asignación de calificaciones ponderadas, demostrando un comportamiento estable y coherente ante transformaciones controladas de las imágenes.

Los resultados obtenidos evidencian que el modelo mantiene una buena consistencia en sus evaluaciones, con desviaciones estándar menores a 0.06 para todos los platillos analizados, lo que indica una alta robustez frente a variaciones leves de iluminación o posición. No obstante, se identificaron algunas limitaciones relevantes: el conjunto de imágenes disponible fue reducido, existieron diferencias de iluminación en ciertos platillos y las calificaciones tendieron a concentrarse en un rango estrecho, sin una separación claramente marcada entre las categorías de calidad. Estos hallazgos sugieren la necesidad de ampliar el rango discriminativo del sistema y de fortalecer la representatividad del conjunto de datos.

Como trabajo futuro, se plantea ampliar las pruebas del sistema utilizando un conjunto más diverso de platillos e imágenes, con el fin de evaluar su comportamiento en condiciones más variadas y obtener un análisis más generalizable. También se considera el desarrollo de un módulo de retroalimentación visual y una interfaz gráfica que permitan integrar los resultados en una plataforma funcional y accesible.

Los resultados obtenidos en esta primera fase constituyen un avance importante hacia la creación de un sistema de evaluación estética automatizado. Si bien el modelo mostró un desempeño estable, se observa que la capacidad discriminativa podría beneficiarse de una exploración futura en la ponderación de métricas, identificándose esto como un área de oportunidad para refinar la sensibilidad del modelo. Esta base técnica permitirá continuar con las siguientes etapas del proyecto, enfocadas en consolidar una herramienta más robusta y completa.

Referencias

- [1] Bossard, L., Guillaumin, M., Van Gool, L. (2014). Food-101 – Mining Discriminative Components with Random Forests. *Lecture Notes in Computer Science*, 8694, 446–461. https://doi.org/10.1007/978-3-319-10599-4_29
- [2] Min, W., Jiang, S., Liu, L., Rui, Y., Jain, R. (2019). A Survey on Food Computing. *ACM Computing Surveys (CSUR)*, 52(5), 1–36. <https://doi.org/10.1145/3329168>
- [3] Kakani, V., Nguyen, V. H., Kumar, P., Kim, H., Pasupuleti, V. R. (2020). A Critical Review on Computer Vision and Artificial Intelligence in the Food Industry. *Journal of Agriculture and Food Research*, 2, 100033. <https://doi.org/10.1016/j.jafr.2020.100033>

- [4] Liu, W., Liu, Y., Wang, Q., Chen, X. (2025). Food Image Recognition: A Review of Methods, Challenges, and Future Directions. *Applied Sciences*, 15(14), 7626. <https://doi.org/10.3390/app15147626>
- [5] Lou, Y., Shen, C., Lin, J. (2018). Food Image Aesthetic Quality Measurement by Distribution Prediction. Stanford University, CS230 Project Report. https://cs230.stanford.edu/projects_spring_2018/reports/8290634.pdf
- [6] Mikhailava, V., Hong, J., Geng, J., Jo, H. (2020). Aesthetic Evaluation of Food Plate Images Using Deep Learning. In *22nd International Conference on Advanced Communication Technology (ICACT)*, 195–198. <https://doi.org/10.23919/icact48636.2020.9061216>
- [7] Wang, Z., Bovik, A. C., Sheikh, H. R., Simoncelli, E. P. (2004). Image Quality Assessment: From Error Visibility to Structural Similarity. *IEEE Transactions on Image Processing*, 13(4), 600–612. <https://doi.org/10.1109/TIP.2003.819861>
- [8] Castillo-Ortiz, I., Álvarez-Carmona, M. Á., Aranda, R., Díaz-Pacheco, Á. (2024). Evaluating Culinary Skill Transfer: A Deep Learning Approach to Comparing Student and Chef Dishes Using Image Analysis. *International Journal of Gastronomy and Food Science*, 38, 101070. <https://doi.org/10.1016/j.ijgfs.2024.101070>